# 비지도학습 - 군집분석

K-means clustering

m^(k), i 차원 x = (x0, ..., xi)

2 2 4 3 0 0 1 1 3 2 3 4 2 4 2 4 3 4 0 3 3 3 4 0 0 4]

```
1. 그룹 평균 m^(k) 초기화
                     2. 그룹 할당 ( argmin[dm, x] )
                     3. 평균 업데이트
                     4. 반복
              가중치를 주지 않아 밀도 차이가 있을 경우 클러스터링이 잘 되지 않음. 초기 K 값은 사용자가 정해야 함.
In [11]: import numpy as np
        import pandas as pd
        import matplotlib.pyplot as plt
        from sklearn.datasets import make_blobs
In [15]: X, y = make_blobs(n_samples=100, n_features =2, centers=5, random_state=10)
In [17]: print(X.shape, y.shape)
       (100, 2) (100,)
In [27]: X[:10]
Out[27]: array([[ -5.57785425, 5.87298826],
               [ 1.62783216, 4.17806883],
               [-6.95088443, -9.02459449],
               [-0.95276902, -5.03431566],
               [ 6.55010412, -7.9123388 ],
               [ -6.67870531, 5.52444477],
              [ -5.52802829, 5.62491189],
               [-8.03866378, -8.91215049],
               [ 5.55912116, -10.06110303],
               [ -7.26457869,
                             4.98882111]])
In [31]: y[:20]
Out[31]: array([3, 1, 4, 2, 0, 3, 3, 4, 0, 3, 4, 3, 0, 2, 0, 3, 1, 2, 0, 3])
In [33]: plt.scatter(X[:,0], X[:,1])
        plt.show()
          7.5
          5.0
          2.5
          0.0
        -2.5
        -5.0
        -7.5
        -10.0
                                               0
                                                      2
                                       -2
                 -8
                        -6
In [61]: # k = 5로 설정해야지~!
        from sklearn.cluster import KMeans
        kmc = KMeans(n_clusters=5, init='random', max_iter=200, random_state=222)
        kmc.fit(X)
        label_kmc = kmc.labels_
In [63]: print(label_kmc)
       2 4 3 2 2 2 1 4 4 0 1 3 1 3 1 0 4 1 1 2 3 2 4 1 3 3 2 0 3 1 3 1 4 4 0 3 1
```

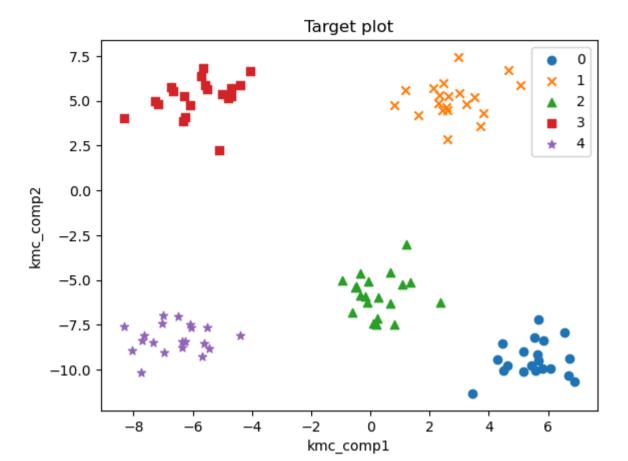
```
In [65]: kmc_columns = ['kmc_comp1', 'kmc_comp2']
         X_kmc_df = pd.DataFrame(X, columns=kmc_columns)
         X_kmc_df['target'] = y
         X_kmc_df['label_kmc'] = label_kmc
         X_kmc_df.head()
Out[65]:
            kmc_comp1 kmc_comp2 target label_kmc
         0
               -5.577854
                            5.872988
                                         3
                                                    0
         1
               1.627832
                            4.178069
                                                    3
         2
               -6.950884
                           -9.024594
                                                    4
                                         4
               -0.952769
                           -5.034316
                           -7.912339
          4
               6.550104
                                         0
                                                    1
In [69]: print(set(X_kmc_df['target']))
         print(set(X_kmc_df['label_kmc']))
        {0, 1, 2, 3, 4}
        \{0, 1, 2, 3, 4\}
In [73]: df = X_kmc_df
         markers = ['o', 'x', '^', 's', '*']
         for i, mark in enumerate(markers):
             df_i = df[df['label_kmc']==i]
             target_i = i
             X1 = df_i['kmc_comp1']
             X2 = df_i['kmc_comp2']
             plt.scatter(X1, X2, marker=mark, label=target_i)
         plt.xlabel('kmc_comp1')
         plt.ylabel('kmc_comp2')
         plt.legend()
         plt.show()
              7.5
                                                                                      1
              5.0
                                                                                      2
                                                                                      3
              2.5
        kmc_comp2
              0.0
             -2.5
             -5.0
            -7.5
           -10.0
                                               -2
                                                                 2
                      -8
                               -6
                                       -4
                                                         0
                                                kmc_comp1
In [75]: # 실제 target plot
         for i, mark in enumerate(markers):
             df_i = df[df['target']==i]
             target_i = i
             X1 = df_i['kmc_comp1']
```

 $X2 = df_i['kmc_comp2']$ 

plt.title('Target plot')
plt.xlabel('kmc\_comp1')
plt.ylabel('kmc\_comp2')

plt.legend()
plt.show()

plt.scatter(X1, X2, marker=mark, label=target\_i)



In [77]: from sklearn.metrics import silhouette\_score
 sil\_score = silhouette\_score(X, label\_kmc)
 print(sil\_score)

0.7598181300128782

# 계층 클러스터링

1. 병합 계층 클러스터링 (Agglomerative) : 개별 데이터 포인트를 하나의 클러스터로 설정하고 시작, 이후 유 사도에 따라 합침.

연결방법 (Linkage Method) : 단일연결(Single Method), 가장 가까운 거리의 데이터를 비교 / 완전 연결(Complete Method) 가장 먼거리의 데이터를 비교

2. 분할 계층 클러스터링 (Divisive) : 전체 데이터 셋을 하나의 클러스터로 놓고 시작, 가장 멀리 떨어진 데이터 를 다른 클러스터로 분리.

Dedrogram 으로 시각화 가능

### 병합계층클러스터링

- 1. 전체 n 개 데이터로 구성된 데이터 셋을 n 개의 클러스터로 설정
- 2. 각 데이터간 거리행렬 D(n\*m) 계산. D 는 대칭행렬
- 3. 거리행렬 D 에서 가장 가까운 클러스터 쌍을 찾아서 합침. (u, v -> uv)
- 4. 거리 행렬에 새로운 클러스터(uv)를 설정하고 행, 열을 추가 및 기존 u, v 행, 열 은 삭제함.
- 5. 단일연결의 경우 min / 완전연결의 경우 max 를 이용해 거리계산을 하여 3-4를 반복함.

Ward's 계층 클러스터링 정보의 손실을 최소화 하는 방향으로 클러스터링, 오차제곱합을 최소화하는 방법 이용 오차제곱합 > 각 데이터포인트가 클러스터 중심에서 얼마나 떨여져 있는 지를 의미함.

- 1. 각 데이터포인트를 하나의 클러스터로 가정, 이 때 오차제곱합은 0이 됨.
- 2. 모든 가능한 클러스터쌍을 고려하여 오차제곱합을 계산 후 가장 작은 오차 제곱합에 해당하는 클러스터를 만듦.
- 3. 반복

print(label\_aggc2)

```
[0 0 0 0 1 1 1 0 1 0]
```

```
In [121... aggc3 = AgglomerativeClustering(n_clusters = 3, linkage='complete')
label_aggc3 = aggc3.fit_predict(X)

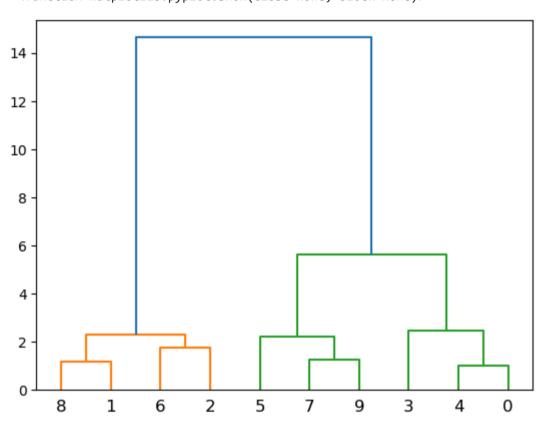
print(label_aggc3)

[2 2 2 0 1 1 1 0 1 0]
```

```
from scipy.cluster.hierarchy import dendrogram
from scipy.cluster.hierarchy import linkage
import matplotlib.pyplot as plt

linked = linkage(X, 'complete')
labels = label_aggc
dendrogram(linked, orientation='top', labels=labels, show_leaf_counts=True)
plt.show
```

Out[129... <function matplotlib.pyplot.show(close=None, block=None)>



## **DBSCAN**

밀집된 영역: 클러스터 vs. 밀집 정도가 낮은 영역: 클러스터 외부 영역 클러스터 개수를 미리 정하지 않음. 포인트간 거리 측정 -> 클러스터의 밀집 정도, 기본:Euclidean

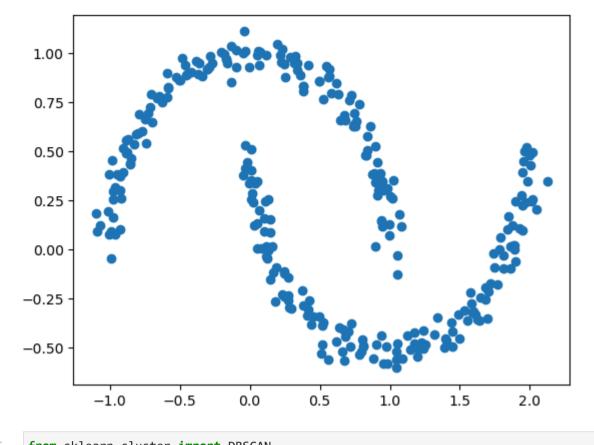
\*\* 반경 내에 외소한의 데이터 포인트 개수 이상이 존재한다. min\_samples : 최소한의 데이터 포인트 개수 (hyperparameter) eps : 데이터 포인트 개수를 측정할 반경

eps 내에 min\_samples 개수 이상 존재하면 core point. eps 내 존재하는 데이터 포인트들 (border point)을 하나의 클러스터로 분류. 초기 핵심 데이터포인트는 무작위로 선정. eps 내 데이터포인트 개수가 min\_samples 이하일 경우 noise로 labeling 함. core point / border point / noise point

- 1. Eps-neighborhood of a point: Neps(x1)
- 2. Directly density-reachable: xn이 Neps(x1)에 속하고 Neps(x1)의 개수가 min\_samples 이상. 항상 대칭적이지 않다.
- 3. Density-reachable
- 4. Density-connected

Cluster C: 데이터포인트 x1이 C에 속할 때 x1에 대해 xn이 density-reachable 하면 xn도 C 에 속하는 것. 이때 x1, xn 은 density connected 하다. Noise: 어떤 C에도 속하지 못한 포인트

```
In [137... from sklearn.datasets import make_moons
    X, y = make_moons(n_samples=300, noise=0.05, random_state=0)
In [139... print(X.shape)
    print(y.shape)
    (300, 2)
    (300,)
In [143... plt.scatter(X[:,0], X[:,1])
    plt.show()
```



```
In [145...
   from sklearn.cluster import DBSCAN
   dbs = DBSCAN(eps=0.2)
   dbs.fit(X)
   label_dbs = dbs.labels_
   print(label_dbs)
   0 1 1 0]
In [147... dbs_columns = ['dbs_comp1', 'dbs_comp2']
   X_dbs_df = pd.DataFrame(X, columns=dbs_columns)
   X_dbs_df['target'] = y
   X_dbs_df['label_dbs'] = label_dbs
   X_dbs_df.head()
```

Out[147... dbs\_comp1 dbs\_comp2 target label\_dbs

```
0
      0.715413
                  -0.494089
                                             0
      0.246789
                                             0
1
                  -0.240091
2
      0.943261
                   0.346800
                                             0
3
      0.973742
                  -0.492901
                                             0
      1.239713
                  -0.411411
```

```
In [149... print(set(X_dbs_df['target']))
    print(set(X_dbs_df['label_dbs']))

{0, 1}
```

```
{0, 1}
```

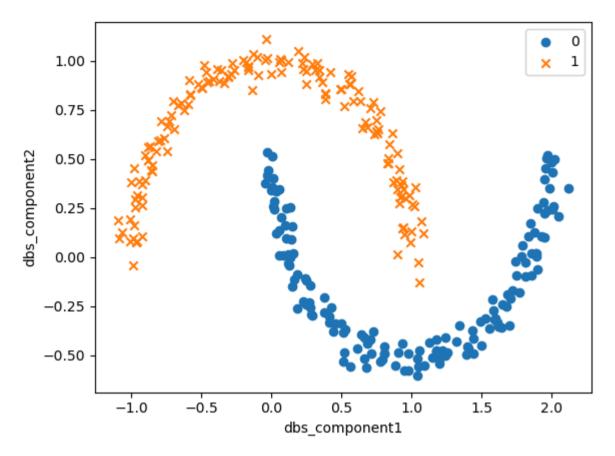
```
In [155...

df = X_dbs_df
markers = ['o', 'x']

for i, mark in enumerate (markers):
    df_i = df[df['label_dbs']==i]
    target_i = i
    X1 = df_i['dbs_comp1']
    X2 = df_i['dbs_comp2']
    plt.scatter(X1, X2, marker=mark, label=target_i)

plt.xlabel('dbs_component1')
plt.ylabel('dbs_component2')

plt.legend()
plt.show()
```

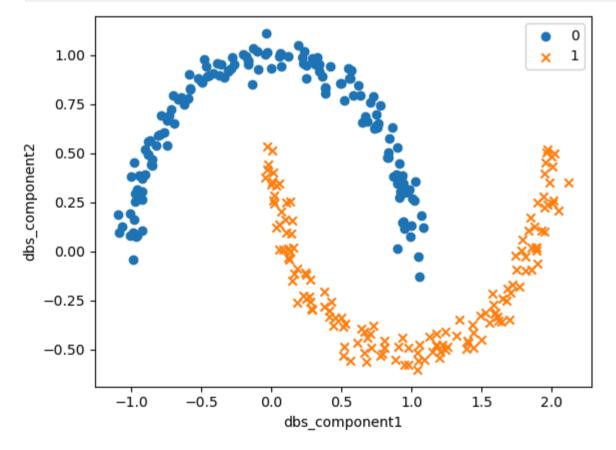


```
In [157... # 실제 타깃

for i, mark in enumerate (markers):
    df_i = df[df['target']==i]
    target_i = i
    X1 = df_i['dbs_comp1']
    X2 = df_i['dbs_comp2']
    plt.scatter(X1, X2, marker=mark, label=target_i)

plt.ylabel('dbs_component1')
plt.ylabel('dbs_component2')

plt.legend()
plt.show()
```



In [159... from sklearn.metrics import silhouette\_score
 sil\_score = silhouette\_score(X, label\_dbs)
 print(sil\_score)

### 0.3284782012631504

# 가우시안 혼합 모형

전체 집단 내부에 속한 하위 집단의 존재를 가정한 확률 모델.

한 하위 집단 당 parameter = (평균 $\mu$ , 표준편차(다변량 $\Sigma$ /단변량 $\sigma$ ), 전체분포에 대한 해당 하위분호의 비율 $\pi$ ) 데이터가 특정 집단에 속하는 경우 ~ 잠재변수(latent variable) z (unobservable)

Parameter를 추정해보자! EM 알고리즘 = E-step & M-step 을 반복하여 로그가능도함수를 증가시키는 방법.

- 1. Initialization  $\mu$ ,  $\sigma$ ,  $\pi$
- 2. E-step: r\_ic (i 번째 데이터가 그룹 c 에서 추출되었을 확률, responsibility) 구하기
- 3. M-setp: 구하고 싶었던 parameter 모두를 구함 ( $\mu$ ,  $\sigma$ ,  $\pi$ ) \* 그룹개수, parameter update

```
In [165... X, y = make_blobs(n_samples=200, n_features=2, centers=2, random_state=2)
In [167... print(X.shape, y.shape)
         (200, 2) (200,)
In [173... plt.scatter(X[:,0], X[:,1])
          plt.show()
            2
            0
           -2
           -4
           -6
           -8
          -10
          -12
                                   -2
                                                                        2
                         <u>-</u>3
                                            -1
                                                                                  3
                -4
```

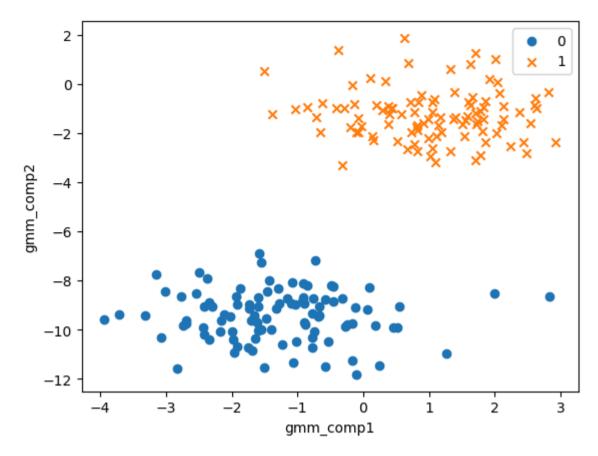
In [177... X

```
Out[177... array([[ 0.38115481, -1.64481461],
                [ -0.58390398, -8.78405909],
                 [ 1.83086535, -1.42523455],
                 [ 1.81313467, -1.92467083],
                 [-1.65577138, -9.55594613],
                [-0.13265422, -0.80505548],
                 [ -2.69891251, -9.73324948],
                 [ 0.18757605, -9.8171527 ],
                 [ 1.92513692, 0.17477999],
                 [-0.24707289, -9.8104778],
                 [0.80420551, -1.74288075],
                 [-1.39452325, -9.97964956],
                 [-1.60515159, -10.04170987],
                 [ 0.83352543, -0.74460559],
                 [-1.46957122, -9.55869403],
                 [ 1.55591864, -1.4580672 ],
                 [ 1.05937597, -0.7579938 ],
                 [ 2.13810493, -1.44566983],
                 [ 1.1848232 , -1.95576116],
                 [-0.37638912, 1.3767851],
                 [-0.6172497, -0.79361238],
                 [-1.68399423, -10.86599403],
                 [ 0.42186795, -1.00112008],
                 [ 0.81825271, -2.73069558],
                 [-0.16344961, -0.05951747],
                 [0.67755635, -2.64355425],
                 [-0.90965742, -8.1218415],
                 [-0.65895073, -1.96921394],
                 [0.44030012, -0.99402533],
                 [-0.91504844, -8.70739333],
                 [-3.01806146, -8.44065141],
                 [-1.02353151, -10.47025441],
                 [ 1.59306999, -0.74416768],
                 [-0.66995787, -9.05797846],
                 [-2.50153112, -7.67699872],
                 [1.10320057, -3.20707537],
                 [-0.58498235, -11.51494191],
                 [-0.4075959, -0.98602662],
                 [ 1.506501 , -1.62839627],
                 [-1.93335222, -8.63901908],
                 [ 0.20550002, -0.86879848],
                 [-2.41442044, -10.18889625],
                 [ 1.62504848, -0.87595942],
                 [0.29507856, -1.05360095],
                 [-1.95777753, -10.92091439],
                 [-1.46335853, -8.46162063],
                 [-1.42824915, -7.98003845],
                 [-0.84660563, -8.20309613],
                 [-0.45064353, -8.8508534],
                 [ 1.71860282, -1.65302661],
                 [-1.5841884, -6.8961805],
                 [-0.72081785, -1.37019171],
                 [-2.76256743, -8.63516347],
                 [-1.55628145, -9.99835926],
                 [ 1.02581503, -2.93411237],
                 [ 0.33970811, 0.11528184],
                  0.82608078, -1.87016308],
                 [-3.93955141, -9.57292799],
                 [ 2.12599563, -0.9232473 ],
                 [-1.2800922, -8.93912279],
                 [ 1.36979547, -1.42903191],
                 [-1.06398595, -11.34008775],
                 [ 0.78454593, -1.15593416],
                 [-1.50834952, -11.55108763],
                 [ -2.34090099, -8.88980884],
                 [ 0.88989739, -0.44520158],
                 [ -1.9993558 , -10.06488996],
                 [ 1.99964344, -8.51061404],
                 [0.70973004, -0.75512788],
                 [ 1.70677401, 1.23618273],
                 [ 1.8230386 , -0.9574862 ],
                 [ -1.66161844, -9.41498635],
                 [-2.30151669, -9.04907966],
                 [ 1.77939563, -1.09938345],
                 [-0.11858047, -9.09539732],
                 [ 1.86284776, -2.38064272],
                 [0.15873435, -2.29051183],
                 [ 1.57945366, -1.31393944],
                 [-0.32431771, -3.31914574],
                 [-1.91775697, -10.66908765],
                 [0.98564842, -2.22738281],
                 [-0.78216181, -9.35497119],
                 [-3.71486953, -9.36874886],
                 [ -1.69941844, -9.61380426],
                 [-1.03866233, -8.98404971],
                 [0.82017839, -1.68889855],
                 [ 2.82419621, -0.35337615],
```

```
[-1.60368203, -9.05765066],
[ 0.62173043, 1.86741382],
[ 2.49020135, -2.82466326],
[0.55523077, -9.04078549],
[-0.45539895, -8.23326244],
[ -0.74104364, -10.07763506],
[-1.29923245, -8.30647414],
[0.77192861, -2.46670777],
[ -1.09969215, -8.92831109],
[0.91100418, -1.59821873],
[-0.06811619, -1.40206897],
[-0.10604775, -1.97508279],
[-0.77824475, -10.32568907],
[ 0.05546421, -9.17884603],
[ 1.86409032, -0.70074535],
[-0.75580553, -8.74619579],
[ -1.97869191, -10.41036729],
[0.99104311, -1.43284403],
[-3.07353754, -10.32322273],
[-2.02797291, -9.47245011],
[-1.54915892, -7.25010857],
[ -0.85715442, -0.96306408],
[ -3.14819261, -7.7502907 ],
 0.08713347, -8.26358973],
[ 2.54154025, -1.60938019],
[ 1.65747097, -0.55866748],
[1.07861399, -0.62821787],
[ 1.13908963, -1.6936582 ],
[-2.18234803, -10.07244764],
[ 1.40927131, -1.35139941],
  1.11435514, -2.1403809 ],
[ 2.07905596, -0.39137275],
[ 2.37703059, -1.1452029],
[ 2.02143446, -2.01543187],
[0.14325405, -2.14589394],
[-0.66876118, -9.43350477],
[ -2.82677657, -11.5641273 ],
[-0.31932001, -8.72310502],
 0.37487407, -0.91475768],
[ -0.10657046, -11.82507855],
[-0.67858614, -9.47781587],
[0.39010877, -1.25159452],
[ 1.62861332, 0.80867712],
[1.05371201, -2.63214103],
[-0.52813711, -10.47523635],
[-1.3196722, -9.15547193],
[0.51326445, -2.31320125],
[ -0.89962999, -9.69861063],
[-0.89823572, -8.91519992],
[-2.53552918, -8.54331169],
[-2.73346631, -9.81949314],
[-1.03011438, -1.02557957],
[ 2.0119666 , 1.00882614],
[-1.07589398, -8.07477912],
[-0.20175034, -1.78148269],
[-0.03026543, -1.74172697],
[-1.74210731, -9.13058687],
[-0.17095868, -11.24639309],
[-1.59361015, -8.71046363],
[-2.15820985, -9.63790953],
[ 1.70084242, -1.17949827],
[-0.28764562, -0.98370587],
[-1.87385754, -8.3319748],
[1.7408485, -1.52644915],
[-2.10923725, -9.39376515],
[ 2.61434254, -0.58086887],
[ 1.38354601, -0.31804274],
  2.82859067, -8.66035449]
[-1.74844822, -10.73619567],
[ 1.17331624, -1.36048319],
[ 1.70531079, -3.09426819],
[-2.33805418, -10.39048298],
[-0.48092196, -8.2188617],
[ 1.54591325, -2.13399516],
[ 0.68097889, 0.85112594],
[ 2.60842583, -0.86794594],
[-1.64458105, -10.35745484],
[-2.41323523, -9.04838281],
[ 2.92640652, -2.36434847],
[ 2.10389484, -1.66689096],
[ -1.73432981, -8.96710465],
[-1.15527831, -8.72497322],
[ 2.24169986, -2.5392787 ],
[ 1.0505005 , -1.13446366],
[-2.70131918, -9.63497056],
[-3.32042501, -9.43521984],
[-1.61892392, -9.71765939],
```

```
[-0.8835818, -9.7960928],
               [ 0.72986148, -1.97091264],
               [ 1.3203166 , -2.74891159],
               [-2.4311049, -9.90799783],
               [ 0.57884096, -1.22623874],
               [ 0.46171023, -9.92897624],
               [-1.38115313, -1.23503221],
               [-0.77722054, -10.72676345],
               [ 2.44441946, -2.35848003],
               [-0.07381757, -1.94648329],
               [ 1.27033628, -10.95464861],
               [ -0.72864791, -7.18926735],
               [ 2.03872755, 0.07546388],
               [-1.23856256, -10.59940081],
               [-2.3788409, -7.89698831],
               [-1.51220857, 0.53244231],
               [ 1.78230921, -2.91522595],
               [-0.27973607, -9.86256788],
               [ 0.110124 , 0.25183468],
               [ 2.6351642 , -0.98185444],
               [-1.91478126, -8.97307912],
               [-0.16221522, -9.75571745],
               [ 0.5124909 , -9.91048868],
               [ 1.32915795, 0.61082376],
               [ 0.25165836, -11.46732114]])
In [179...
        from sklearn.mixture import GaussianMixture
        gmm = GaussianMixture(n_components=2, random_state=0)
        gmm.fit(X)
        label_gmm = gmm.predict(X)
        print(label_gmm)
        [1\ 0\ 1\ 1\ 0\ 1\ 0\ 0\ 1\ 0\ 1\ 0\ 1\ 1\ 1\ 1\ 1\ 1\ 1\ 1\ 1\ 1\ 1\ 0\ 1\ 1\ 0\ 0\ 0\ 1\ 0\ 0\ 1\ 0
        001001101100010]
In [181... gmm_columns = ['gmm_comp1', 'gmm_comp2']
        X_gmm_df = pd.DataFrame(X, columns=gmm_columns)
        X_gmm_df['target'] = y
        X_gmm_df['label_gmm'] = label_gmm
        X_gmm_df.head()
Out[181...
           gmm_comp1 gmm_comp2 target label_gmm
         0
              0.381155
                         -1.644815
                                              1
         1
                                              0
              -0.583904
                         -8.784059
         2
              1.830865
                         -1.425235
                                              1
         3
              1.813135
                         -1.924671
                                     1
                                              1
                                     0
                                              0
         4
              -1.655771
                         -9.555946
        print(set(X_gmm_df['target']))
In [183...
        print(set(X_gmm_df['label_gmm']))
       \{0, 1\}
       \{0, 1\}
In [187... df = X_gmm_df
        markers = ['o', 'x']
        for i, mark in enumerate(markers):
            df_i = df[df['label_gmm']==i]
            target_i = i
            X1 = df_i['gmm\_comp1']
            X2 = df_i['gmm_comp2']
            plt.scatter(X1, X2, marker = mark, label = target_i)
        plt.xlabel('gmm_comp1')
        plt.ylabel('gmm_comp2')
        plt.legend()
         plt.show()
```

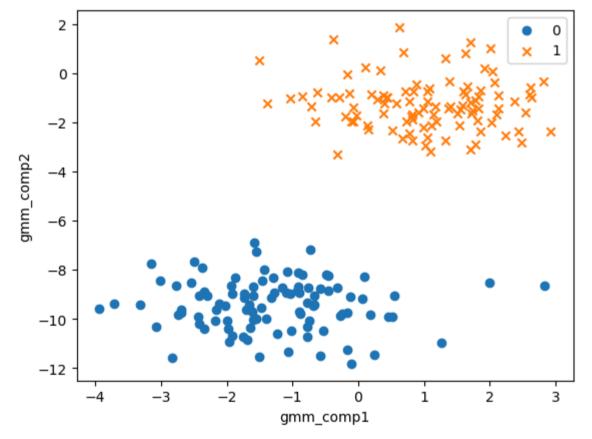
[-0.92096863, -8.85925495],



```
In [189... # 실제 target plot

for i, mark in enumerate(markers):
    df_i = df[df['target']==i]
    target_i = i
    X1 = df_i['gmm_comp1']
    X2 = df_i['gmm_comp2']
    plt.scatter(X1, X2, marker = mark, label = target_i)

plt.xlabel('gmm_comp1')
plt.ylabel('gmm_comp2')
plt.legend()
plt.show()
```



```
In [193... from sklearn.metrics import silhouette_score
    sil_score = silhouette_score(X, label_gmm)
    print(sil_score)
```

0.7842908753561848

In [ ]: